

基于深度卷积神经网络的青菜和杂草识别

金慧萍¹, 牟海雯², 刘腾², 于佳琳², 金小俊^{2,3*}

(1.南京林业大学工程培训中心,南京 210037; 2.北京大学现代农业研究院,山东 潍坊 261325;
3.南京林业大学机械电子工程学院,南京 210037)

摘要:针对青菜田间杂草种类繁多且分布复杂导致识别效率低、精度差和稳健性不足等问题,以苗期青菜及其伴生杂草为研究对象,提出了一种基于深度卷积神经网络的青菜和杂草识别方法。首先使用图像处理方法标记出包含绿色植物的图像,进而利用神经网络模型对青菜和杂草进行区分。为探究不同神经网络模型的识别效果,分别选取 DenseNet 模型、GoogLeNet 模型和 ResNet 模型对图像中包含青菜或者杂草图像进行识别,并以 F_1 值、总体准确率和识别速度作为评价依据。结果表明,3种神经网络模型均能有效区分青菜和杂草,其中 ResNet 模型为最优模型,其在测试集的总体准确率和识别速度分别为 97.2% 和 78.34 帧 \cdot s⁻¹。提出的青菜和杂草识别方法可有效降低杂草识别的复杂度,并能够提升识别的稳健性和泛化能力,为青菜田间杂草精准防控的研究奠定基础。

关键词:深度学习;卷积神经网络;青菜识别;杂草识别

doi:10.13304/j.nykjdb.2023.0873

中图分类号:S126;TP391.41

文献标志码:A

文章编号:1008-0864(2024)08-0122-09

Bok Choy and Weed Identification Based on Deep Convolutional Neural Networks

JIN Huiping¹, MOU Haiwen², LIU Teng², YU Jialin², JIN Xiaojun^{2,3*}

(1.Engineering Training Center, Nanjing Forestry University, Nanjing 210037, China; 2.Institute of Advanced Agriculture Sciences, Peking University, Shandong Weifang 261325, China; 3.College of Mechanical and Electronic Engineering, Nanjing Forestry University, Nanjing 210037, China)

Abstract: Due to the diversity and complex distribution of weeds in bok choy fields, the existing methods for weed identification have the problems of low efficiency, poor accuracy and lack of robustness. This study proposed a method to identify bok choy and weeds based on deep convolutional neural networks, using seedling stage bok choy and their associated weeds as the research objects. Firstly, image processing methods were used to mark images containing green plants, and then a neural network model was used to distinguish bok choy and weeds. In order to investigate the recognition effect of different neural network models, the DenseNet model, GoogLeNet model and ResNet model were used to recognize images containing bok choy or weed images, and the F_1 value, overall accuracy and recognition speed were used as evaluation criteria. The experimental results showed that the 3 neural network models could effectively distinguish bok choy and weeds, and the ResNet model was the optimal model, with an overall accuracy and recognition speed of 97.2% and 78.34 frames \cdot s⁻¹ on the testing datasets, respectively. The bok choy and weed identification method proposed in this study could effectively reduce the complexity of weed identification, improve the robustness and generalization ability of identification, and laid the foundation for the research on precision weed control in bok choy fields.

Key words: deep learning; convolutional neural network; bok choy recognition; weed recognition

收稿日期:2023-11-28; 接受日期:2024-02-06

基金项目:国家自然科学基金项目(32072498);江苏省研究生科研与实践创新计划项目(KYCX22_1051)。

联系方式:金慧萍 E-mail: jinhuiping713@163.com; *通信作者 金小俊 E-mail: xiaojun.jin@pku-iaas.edu.cn

我国是蔬菜产销大国,蔬菜种类和品种极为丰富,种植面积巨大^[1]。近年来,我国蔬菜种植面积已突破3.0亿亩(0.2亿 hm^2),产量超过7亿 t ^[2]。蔬菜产业是我国种植业的第二大产业,也是农业农村经济发展的支柱产业^[3]。杂草是影响蔬菜苗期生长的主要因素之一,及时进行田间除草可减少与蔬菜养分争夺、发育迟缓以及病虫害等问题,是保障蔬菜增产的必要措施^[4]。当前青菜田除草方式仍然以人工为主,劳动强度高、效率低,随着人工成本的不断提升,青菜种植成本也不断被推高,严重威胁蔬菜产业的可持续发展^[5-8],新型、绿色除草方式的研究和推广迫在眉睫。为此,以精准除草为理念的机械除草、电击除草等方式被广泛研究^[9-13]。在智慧农业背景下,智能化除草装备的研究尤为重要,而杂草的快速、精准识别是实现精准除草的关键^[14-15]。

传统杂草识别方法一般采用图像处理技术,通过对比杂草的形状特征、颜色特征、纹理特征或多光谱特征区分杂草与作物^[16-19]。Marhant等^[20]以颜色和位置特征为识别参数,采用贝叶斯分类器来区分花菜(*Brassica oleracea* L.var. botrytis L.)、杂草和土壤,在获取准确先验概率条件下,错误分类率最低为6.4%。毛文华等^[21]利用植物的多特征实现田间杂草的精准自动识别,使用颜色特征分割土壤背景,并通过位置和纹理特征识别杂草,最后采用形态特征处理误识别的作物和杂草。何东健等^[22]通过提取植物叶片的形状、纹理及分形维数3类特征,使用SVM-DS(support vector machine-dempster/shafer)多特征决策融合识别杂草。上述杂草识别方法多依赖图像特征的人工提取和选择,在特定环境下识别效果尚佳,但杂草种类繁多、特征各异,且人工设计的特征易受光照和背景噪声等环境因素的影响,在杂草识别过程中存在精度低、速度慢、稳健性不足等缺陷^[23-24]。近年来,随着深度学习技术的发展,利用深度卷积神经网络(convolutional neural networks, CNNs)的人工智能杂草识别技术已成为目前研究的主流方向。

深度学习是利用神经网络分析样本数据的内在特征和表达层次,学习具有多个抽象层次的数据表示的机器学习技术^[25],广泛应用于自然语言处理(natural language process, NLP)、计算机视觉、

语音识别等方面,基于深度学习的杂草识别研究正广泛开展^[26-28]。Osorio等^[29]利用基于支持向量机(SVM)的机器学习技术和基于YOLO-v3、Mask R-CNN的深度学习模型对生菜田中的杂草进行识别。孙哲等^[30]以西兰花幼苗为研究对象,提出了一种基于Faster R-CNN模型的作物检测方法。该方法从复杂数据中学习西兰花幼苗的特征,增强了模型的稳健性。以ResNet50网络、ResNet101网络和VGG16网络作为特征提取器进行对比试验,并确定以ResNet101网络为最优特征提取网络,设Dropout值为0.6,其平均精度达到91.73%。

当前基于深度学习的杂草识别研究通常采用直接识别杂草的方式,但杂草种类繁多,训练模型时需要采集不同种类、数量众多的杂草图像作为训练集数据,成本极其高昂。同时,神经网络模型也难以对所有杂草都保持高识别率。众多研究者采用目标检测网络对杂草进行识别^[31],但杂草边界框的尺寸多变,而机械除草执行器的作业范围或除草剂的喷施范围往往是固定的,这使得目标检测网络的识别结果难以与除草执行器的作业区域直接匹配。为降低杂草识别复杂度,同时提高杂草识别率,本文使用神经网络模型对青菜和杂草进行区分,通过识别青菜间接识别杂草。该方法有效降低了神经网络模型数据集搭建成本,并能够提升模型识别的稳健性和泛化能力,可为智能除草装备中的杂草识别研究提供参考。

1 材料与方法

1.1 图像采集与样本数据集

本研究以青菜幼苗及其伴生杂草为研究对象,为保证数据集的多样性,所采集的图像包含环境、光线以及生长差异下的青菜和杂草。试验数据于2021年7月和9月采自江苏省南京市八卦洲的蔬菜园,使用佳能EOS 600D数码相机(1 800万像素CMOS传感器,搭配DIGIC 4处理器)垂直拍摄,相机距离地面约60 cm,图像分辨率为1 792×1 344像素,格式为JPEG。对于采集到的图像,按照6行8列均匀切分成48张网格图像,每张网格图像分辨率为224×224像素。网格图像经人工分类后作为神经网络模型训练集和测试集的图像数据。

1.2 杂草识别

本研究采用识别青菜进而区分杂草的方法实现对苗期青菜伴生杂草的识别。首先利用颜色特征标记包含绿色植物(青菜和杂草)的图像,以此排除土壤部分的网格图像。对于植物图像,进一

步使用分类神经网络模型进行青菜和杂草的区分。训练神经网络模型时,将所有包含青菜的网格图像归为真正类,反之为真负类,即神经网络模型仅需识别出包含青菜的图像,未包含青菜的图像则认为是杂草图像,杂草识别流程如图1所示。

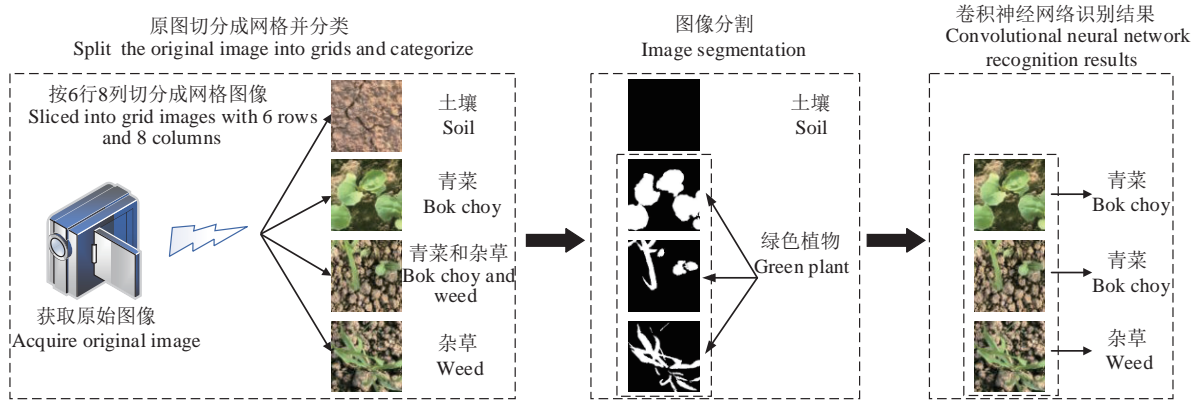



图1 杂草识别流程

Fig. 1 Flow of weed identification

1.3 图像处理

根据网格图像包含的内容将场景归类为4种:仅包含土壤(图2A)、仅包含青菜(图2B)、既包含青菜又包含杂草(图2C)、仅包含杂草(图2D)。采用 Morid 等^[32]和 Jin 等^[33]提出的颜色因子对绿色植物进行分割,青菜和杂草在图像中呈现

绿色,而土壤为黄褐色,在RGB颜色空间中,青菜和杂草的G(绿色)分量必然大于R(红色)分量或B(蓝色)分量。由此,可对该颜色因子进行条件式改造,以进一步提升其图像分割效果。改进后的颜色因子如式(1)所示。



A: 仅包含土壤; B: 仅包含青菜; C: 既包含青菜又包含杂草; D: 仅包含杂草

A: Soil only; B: Bok choy only; C: Contain both bok choy and weed; D: Weed only

图2 不同场景类型的网格图像

Fig. 2 Grid images of different scene types

$$\text{index} = \begin{cases} 0, & \text{if } (G < R \text{ or } G < B) \\ -19R + 24G - 2B > 862, & \text{otherwise} \end{cases} \quad (1)$$

式中, R 为像素红色分量值、 G 为像素绿色分量值、 B 为像素蓝色分量值, -19 、 24 、 -2 为颜色因子的系数,862为颜色因子的常量值。

遍历网格图像中的每个像素点,首先判断其

G 分量是否小于 R 分量或 B 分量,若是则将其像素值置为0(背景),反之应用颜色因子进一步计算。若 $-19R + 24G - 2B > 862$,则将该像素点赋值为1(植物),反之为0(背景)。由于背景颜色值的影响,分割后的图像会存在若干噪点。噪点通常面积较小并随机分散于图像各处,需要进行滤波操作以消除噪点,提升分割效果。本文采用面积滤

波对分割图像进行后处理,通过计算并标记像素连通区域,将低于面积阈值的区域标记为噪点,并从图像中移除。图像预处理后,剔除未包含植物像素的网格图像,将剩余包含植物的网格图像输入神经网络模型进行青菜和杂草识别。

1.4 实验环境

使用PyTorch框架^[34]进行深度学习,其具有灵活性高、易用性强和速度快的优点^[35]。本文神经网络模型的训练在搭载NVIDIA GeForce RTX 2080Ti图形处理单元(GPU)的台式计算机上进行。计算机的处理器(CPU)为Inter® core™

i9-9900K CPU@3.60 GHz,运行内存为64 GB,操作系统为乌班图(Ubuntu),版本20.04。

1.5 深度学习模型

在分析各深度学习模型特点的基础上,本研究分别选取了最为经典且被广泛应用于各个领域的DenseNet模型、GoogLeNet模型和ResNet模型对网格图像中包含青菜的图像进行识别并对比分析各模型的识别效果。本文将从识别率和识别速度两方面对这3种模型识别杂草的效果进行对比和分析,并根据评价结果确定青菜和杂草识别的最优模型。各模型的默认超参设置如表1所示。

表1 不同模型的超参设置

Table 1 Hyper-parameters used for training the neural networks

神经网络模型 Neural network	优化器 Optimizer	初始学习率 Base learning rate	学习率调整策略 Learning rate policy	批尺寸 Batch size	训练周期 Training epochs
DenseNet	SGD	0.001 0	LambdaLR	16	24
GoogLeNet	Adam	0.000 3	StepLR	16	24
ResNet	Adam	0.000 1	StepLR	16	24

1.6 训练数据

将采集到的每幅图像按照6行8列切分成48幅网格图像,切分后每张网格图像的分辨率为224×224像素。人工查看网格图像并分类,将包含青菜的网格图像和既有青菜又有杂草的网格图像归为青菜类;将只包含杂草的图像归为杂草类,如此分别得到青菜样本和杂草样本各6 200幅。所有样本按照比例随机分为训练集、验证集和测试集,其中训练集样本共计10 000幅(青菜和杂草各5 000幅),验证集样本共计1 200幅(青菜和杂草各600幅),测试集样本数量同验证集。所有样本均为原始图像,未进行数据扩增。

1.7 评价指标

采用精度(precision, P)、召回率(recall, R)、F₁值以及总体准确率(overall accuracy, OA)作为图像分类的评价指标。精度表示正确检测出青菜目标与预测为青菜目标的比值,召回率表示所有青菜目标被正确预测的比例。F₁值是图像分类中基于精度与召回率的综合评价指标,总体准确率(OA)是神经网络模型预测正确的数量与总体数量之间的比值,计算公式如下。

$$P = \frac{TP}{TP + FP} \quad (2)$$

$$R = \frac{TP}{TP + FN} \quad (3)$$

$$F_1 = \frac{2 \times P \times R}{(P + R)} \quad (4)$$


$$OA = \frac{TP + TN}{TP + FP + FN + TN} \quad (5)$$

式中,TP(true positive)为被正确划分为正样本的数量;FP(false positive)为被错误划分为正样本的数量;TN(true negative)为被正确划分为负样本的数量;FN(false negative)为被错误划分为负样本的数量。

2 结果与分析

2.1 颜色因子分割效果

通过图像处理方法,利用颜色特征分割出网格图像中的绿色植物。图3所示为应用改进后的颜色因子和面积滤波后得到的分割效果,可以看出,颜色因子成功分割出青菜和杂草像素,且效果极佳。其中,图3A仅包含土壤背景分割后无植物像素,可以直接剔除。图3B~3D包含植物目标,需要进一步对青菜和杂草进行识别和区分。



A: 土壤背景分割;B:青菜目标分割;C:青菜和杂草目标分割;D:杂草目标分割
A: Soil background division; B: Bok choy division; C: Bok choy and weed division; D: Weed division

图3 绿色植物分割效果

Fig. 3 Green plants division effect

2.2 青菜和杂草识别

2.2.1 不同模型验证集数据评价 神经网络模型识别青菜和杂草的验证集评价结果如表2所示。ResNet模型识别青菜的精度最高(0.977),精度值越高表示其对青菜的误识别率越低。若将青菜误识别为杂草,则会造成在除草时误伤作物。GoogLeNet模型识别青菜的精度最低,仅为0.948。召回率方面,ResNet模型和DenseNet模型对于杂

草的召回率都高达0.977。而GoogLeNet模型只能够识别出0.947的杂草目标,表明其有0.053的漏检率。进一步观察总体准确率和 F_1 值,ResNet模型的总体准确率最高,为0.975,DenseNet模型其次,而GoogLeNet模型只有0.957,是所有模型中总体准确率最低的。 F_1 值的结果与总体准确率相近,ResNet模型的 F_1 值最高,为0.975,表明其在识别青菜和杂草时能更好的兼顾精度和召回率。

表2 不同神经网络模型验证集评价数据

Table 2 Evaluation matrix of CNN models in validation datasets

神经网络模型 Neural network	目标 Target	精度 Precision	召回率 Recall	总体准确率 Overall accuracy	F_1 值 F_1 score
DenseNet	青菜 Bok choy	0.976	0.968	0.972	0.972
	杂草 Weed	0.969	0.977	0.972	0.973
GoogLeNet	青菜 Bok choy	0.948	0.967	0.957	0.957
	杂草 Weed	0.966	0.947	0.957	0.956
ResNet	青菜 Bok choy	0.977	0.973	0.975	0.975
	杂草 Weed	0.973	0.977	0.975	0.975

2.2.2 不同模型测试集数据评价 相较于验证集的结果,测试集的数据(表3)都略有下降,但各模型的总体准确率和 F_1 值都高于0.953,表明神经网络模型可以有效地识别青菜和杂草。其中,ResNet模型对于青菜和杂草的总体准确率为0.972, F_1 值为0.971,对比GoogLeNet模型和DenseNet模型展现了最佳的识别效果。


2.2.3 不同模型混淆矩阵分析 图4所示为DenseNet模型、GoogLeNet模型和ResNet模型在测试集的混淆矩阵。可以看出,DenseNet模型在识别青菜时,将14幅杂草图像错误地识别为青菜

图像,同时,将26幅青菜图像误认为杂草图像。而GoogLeNet模型的低识别率主要归结于将34幅杂草图像错误地预测为青菜。ResNet模型更善于识别杂草,仅有13幅杂草图像被误识别为青菜,而青菜被误识别为杂草的数量则有21幅。

ResNet模型识别错误的图像如图5所示,当青菜和杂草只占图像极少部分时,模型难以正确区分其归属,然而该场景虽降低了青菜和杂草的识别率,但并不会对除草应用产生较大影响。若青菜被误识别为杂草,因其目标区域极小,除草执行器不会对青菜产生实质伤害;若杂草被误识别

表 3 不同神经网络模型测试集评价数据
Table 3 Evaluation matrix of CNN models in testing dataset

神经网络模型 Neural network	目标 Target	精度 Precision	召回率 Recall	总体准确率 Overall accuracy	F ₁ 值 F ₁ score
DenseNet	青菜 Bok choy	0.976	0.957	0.967	0.966
	杂草 Weed	0.958	0.977	0.967	0.967
GoogLeNet	青菜 Bok choy	0.945	0.965	0.954	0.955
	杂草 Weed	0.964	0.943	0.954	0.953
ResNet	青菜 Bok choy	0.978	0.965	0.972	0.971
	杂草 Weed	0.965	0.978	0.972	0.971



A: DenseNet 模型混淆矩阵; B: GoogLeNet 模型混淆矩阵; C: ResNet 模型混淆矩阵

A: DenseNet model confusion matrix; B: GoogLeNet model confusion matrix; C: ResNet model confusion matrix

图 4 神经网络模型测试集混淆矩阵


Fig. 4 Confusion matrices of the neural networks in testing datasets

为青菜,则该区域的杂草部分会被忽略,但处于另一网格的杂草主体部分会被识别。另一方面,也可以通过提高图像预处理时的面积滤波阈值,以滤除占比较小的青菜和杂草图像,统一作为无需除草作业的网格区域。

2.2.4 不同模型识别速度分析 表 4 展示了 DenseNet 模型、GoogLeNet 模型和 ResNet 模型的青

菜和杂草识别速度。识别速度取测试集图像(1 200 幅)识别速度的平均值。由于网格图像为相机拍摄的原始图像按照 6 行 8 列均匀切分所得(每幅原图划分为 48 幅网格图像),因而在计算识别速度时可将批尺寸设置为 48,如此所得数值即为原始图像的识别速度。从表 4 可知,ResNet 模型和 GoogLeNet 模型的识别速度相近,识别 1 幅原图分别耗时 12.76 和 12.38 ms。DenseNet 模型的识别速度最低,为 19.44 ms·幅⁻¹。综合识别率和识别速度,ResNet 模型为青菜和杂草识别的最优模型,其识别帧率为 78.34 帧·s⁻¹,满足实时杂草识别的应用需求。

杂草识别整体效果如图 6 所示。仅包含土壤、仅包含杂草、仅包含青菜以及既包含青菜又包含杂草的 4 类网格图像先利用图像处理技术识别出包含绿色植物的网格图像,进而利用神经网络模型对青菜和杂草进行区分,识别出包含青菜的网格图像,从而剩下的为仅包含杂草的网格图像。



A: 青菜网格图像; B: 杂草网格图像

A: Grid image of bok choy; B: Grid image of weed

图 5 ResNet 模型识别错误样本

Fig. 5 Examples of erroneous detection with ResNet

表 4 不同模型的识别速度
Table 4 Recognition speed of different models

神经网络模型 Neural network	批尺寸 Batch size	图像计算数量 Image calculations	识别速度/(ms·幅 ⁻¹) Recognition speed/(ms·image ⁻¹)	帧率/(帧·s ⁻¹) Frame per second/(frames·s ⁻¹)
DenseNet	48	1 200	19.44	51.43
GoogLeNet	48	1 200	12.38	80.80
ResNet	48	1 200	12.76	78.34

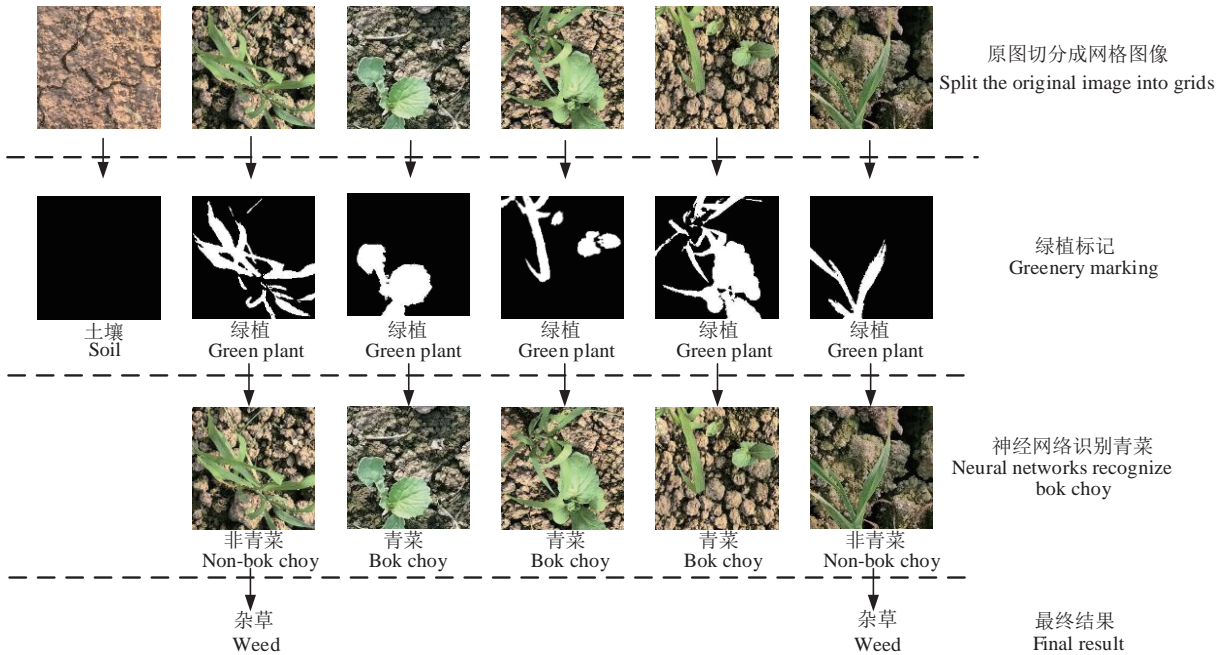


图 6 整体识别效果

Fig. 6 Overall recognition effect

3 讨论

PyTorch 基本框架采用 Python 语言编写,源码简洁明了,不仅提供了强大的 GPU 加速的张量计算,同时也包含了自动求导系统的深度神经网络,是目前使用较为广泛的深度学习平台之一^[36-37]。DenseNet 模型使用旁路设置和特征重用 2 种结构,可以缩减网络参数数量,并对梯度消失起到一定的缓解作用^[38]。青菜和杂草形态多为相似,DenseNet 模型提取细微特征的能力理论上对于杂草识别具有较大优势。GoogLeNet 模型是由 Google 公司推出的基于 Inception 模块的深度神经网络模型,整个网络结构由 22 层构成,拥有 2 个辅助输出模块^[39]。通过提取高维特征以减少参数数量并提高模型的分类性能。使用高效和简洁的 GoogLeNet 模型从多角度分析图像在杂草识别任务中具有重要的探索意义。ResNet 模型是由 He

等^[40]提出的网络结构,充分利用浅层网络信息,可以解决模型梯度消失和梯度爆炸的问题。本研究结果表明,DenseNet 模型和 ResNet 模型的识别总体准确率和 F₁ 值均高于 0.966,充分展现了其网络特点和结构优势。GoogLeNet 模型虽然通过降低模型复杂度提高了计算效率,但识别精度低于 DenseNet 模型和 ResNet 模型。

东辉等^[31]提出一种基于优化 YOLO-v4 和图像处理的蔬菜苗田杂草检测算法,可有效识别蔬菜幼苗期 7 种常见蔬菜和田间杂草。然而杂草种类繁多,搭建数量众多的训练集样本库和高精度识别每种杂草都是极具挑战的任务。本研究在利用分类神经网络模型识别青菜和杂草,将识别目标分为青菜和非青菜,非青菜图像即为杂草图像。即使遇到未在训练集中出现的杂草种类,也不影响识别结果,只要图像中未发现青菜目标,即认为该图像为杂草图像。总体而言,相比较传统杂草

识别方法,本研究提出的方法有效降低了杂草识别的总体复杂度。在深度学习方面,能够以极低的数据集搭建成本构建高稳健性和泛化能力的神经网络模型。

本研究使用网格图像训练和测试神经网络模型,每幅原图可划分为48幅网格图像。因为网格在图像中的位置为已知信息,故而识别所有包含杂草的网格图像后可以直接确定杂草在原图中的区域,除草设备移动到包含杂草的网格区域即可进行除草工作。本研究中每幅网格图像尺寸为224×224像素,在实际应用中,可根据除草执行器的作业范围设置网格图像尺寸,使得执行器的作业范围覆盖每个网格区域。

需要特别指出的是,如果网格图像中既包含青菜又包含杂草(图2C),按照本研究的方法,该图像会被识别为青菜图像。青菜通常不使用除草剂喷施除草。在实际应用中,若采用机械除草方式对该区域进行除草作业会伤害作物。因而,对于距离作物较近的杂草仍然需要人工除草或通过多次作业、拍摄不同位置的原图使青菜和杂草处于不同网格中。另外,也可设置更小尺寸的网格图像以实现更精细化的识别。

本文结合图像处理和深度学习技术研究了一种聚焦青菜识别进而间接区分杂草和青菜的识别方法。试验结果表明,本文提出的青菜和杂草识别方法极大地降低了杂草识别的复杂度和神经网络模型训练集的搭建成本,并且解决了传统杂草识别方法中杂草种类繁多情况下识别困难的问题,为青菜田杂草识别提供了低复杂度、高稳健性和泛化能力的解决方案。

参 考 文 献

- [1] 陆海涛,吕建强,金伟,等.我国叶类蔬菜机械化收获技术的发展现状[J].农机化研究,2018,40(6):261-268.
LU H T, LYU J Q, JIN W, *et al.* The current situation of the mechanized harvesting technology development of leaf vegetable in China [J]. J. Agric. Mach. Res., 2018, 40(6): 261-268.
- [2] JIANG P H, YI H L, LI P Y, *et al.* Acidification and salinization of soils with different initial pH under greenhouse vegetable cultivation [J]. J. Soil Sediments, 2014, 14(10): 1683-1692.
- [3] 廖禹,潘松,黄俊宝,等.蔬菜生产机械化技术的现状与发展研究[J].粮食科技与经济,2018,43(10):99-101.
LIAO Y, PAN S, HUANG J B, *et al.* Research on the status and development of vegetable production mechanization technology [J]. Grain Sci. Technol. Econ., 2018, 43(10): 99-101.
- [4] 王璨,武新慧,张燕青,等.基于移位窗口Transformer网络的玉米田间场景下杂草识别[J].农业工程学报,2022,38(15):133-142.
WANG C, WU X H, ZHANG Y Q, *et al.* Recognizing weeds in maize fields using shifted window transformer network [J]. Trans. Chin. Soc. Agric. Eng., 2022, 38(15): 133-142.
- [5] DEBALINA S H, BERT M C, MANJOT K S. A review of Non-chemical weed control practices in christmas tree production [J]. Forests, 2020, 11(5): 554.
- [6] GAINES T A, BUSI R, KÜPPER A. Can new herbicide discovery allow weed management to outpace resistance evolution? [J]. Pest. Manage. Sci., 2021, 77(7): 3036-3041.
- [7] ANNE M, BENJAMIN F, MIKA L, *et al.* Risk in the circular food economy: Glyphosate-based herbicide residues in manure fertilizers decrease crop yield [J/OL]. Sci. Total Environ., 2021, 750: 141422 [2024-03-19]. <https://doi.org/10.1016/j.scitotenv.2020.141422>.
- [8] 魏春生.蔬菜田间化学除草技术及注意事项分析[J].农民致富之友,2019(1):134.
- [9] GERHARDS R, ANDÚJAR S D, HAMOUZ P, *et al.* Advances in site-specific weed management in agriculture—a review [J]. Weed Res., 2022, 62(2): 123-133.
- [10] REKHA R, THUY T N, DAVID C S, *et al.* Real-time robotic weed knife control system for tomato and lettuce based on geometric appearance of plant labels [J]. Biosyst. Eng., 2020, 194: 152-164.
- [11] MARTIN V B, CHRISTIAN M, FABIENNE V B, *et al.* Thermal weed control technologies for conservation agriculture—a review [J]. Weed Res., 2020, 60(4): 241-250.
- [12] 兰天,李端玲,张忠海,等.智能农业除草机器人研究现状与趋势分析[J].计算机测量与控制,2021,29(5):1-7.
LAN T, LI D L, ZHANG Z H, *et al.* Analysis on research status and trend of intelligent agricultural weeding robot [J]. Comput. Meas. Control, 2021, 29(5): 1-7.
- [13] 孙艳霞,陈勇,金小俊,等.除草机器人减震悬架越障性能分析[J].农业机械学报,2013,44(S1):264-268.
SUN Y X, CHEN Y, JIN X J, *et al.* Structure design and simulation analysis of weeding robot. [J]. Trans. Chin. Soc. Agric. Mach., 2013, 44(S1): 264-268.
- [14] 金小俊,陈勇,孙艳霞.农田杂草识别方法研究进展[J].农机化研究,2011,33(7):23-27,33.
JIN X J, CHEN Y, SUN Y X. Research advances of weed identification in agricultural fields [J]. J. Agric. Mach. Res., 2011, 33(7): 23-27, 33.
- [15] 毛文华,张银桥,王辉,等.杂草信息实时获取技术与设备研究进展[J].农业机械学报,2013,44(1):190-195.
MAO W H, ZHANG Y Q, WANG H, *et al.* Advance techniques and equipments for real-time weed detection [J]. Trans. Chin. Soc. Agric. Mach., 2013, 44(1): 190-195.
- [16] PEDRO J H, JOSÉ D, ÁNGELA R. A novel approach for weed type classification based on shape descriptors and a fuzzy decision-making method [J]. Sensors, 2014, 14(8): 15304-15324.

- [17] TANG L, TIAN L, STEWARD B L. Color image segmentation with genetic algorithm for in-field weed sensing [J]. *Trans. Am. Soc. Agric. Eng.*, 2000,43(4):1019-1027.
- [18] ADEL B, ABDOLABBAS J, SEYED M N, *et al.* Weed segmentation using texture features extracted from wavelet sub-images [J]. *Biosyst. Eng.*, 2017,157:1-12.
- [19] 程玉柱,陈勇,车军,等. 基于 Bayes 与 SVM 的玉米彩色图像分割新算法[J]. *江苏农业科学*, 2012,40(7):355-358.
- [20] MARCHANT J A, ONYANGO C M. Comparison of a Bayesian classifier with a multilayer feed-forward neural network using the example of plant/weed/soil discrimination [J]. *Comput. Electron. Agric.*, 2003,39(1):3-22.
- [21] 毛文华,曹晶晶,姜红花,等. 基于多特征的田间杂草识别方法[J]. *农业工程学报*, 2007(11):206-209.
MAO W H, CAO J J, JIANG H H, *et al.* In-field weed detection method based on multi-features [J]. *Trans. Chin. Soc. Agric. Eng.*, 2007(11):206-209.
- [22] 何东健,乔永亮,李攀,等. 基于 SVM-DS 多特征融合的杂草识别[J]. *农业机械学报*, 2013,44(2):182-187.
HE D J, QIAO Y L, LI P, *et al.* Weed recognition based on SVM-DS multi-feature fusion [J]. *Trans. Chin. Soc. Agric. Mach.*, 2013,44(2):182-187.
- [23] KONSTANTINOS G L, PATRIZIA B, DIMITRIOS M, *et al.* Machine learning in agriculture: a review [J/OL]. *Sensors*, 2018,18(8):2674 [2024-03-19]. <https://doi.org/10.3390/s18082674>.
- [24] 仇裕淇,黄振楠,阮昭,等. 机器视觉技术在农业生产智能化中的应用综述[J]. *机械研究与应用*, 2019,32(2):202-206.
QIU Y Q, HUANG Z N, RUAN Z, *et al.* Review on application of machine vision in intelligent agricultural production [J]. *Mech. Res. Appl.*, 2019,32(2):202-206.
- [25] 陈自宏,邓干然,崔振德,等. 基于深度学习的农作物检测识别研究现状及展望[J]. *现代农业装备*, 2022,43(2):2-7.
CHEN Z H, DENG G R, CUI Z D, *et al.* Research status and prospect of crop detection and identification based on deep learning [J]. *Mod. Agric. Equip.*, 2022,43(2):2-7.
- [26] WANG A C, ZHANG W, WEI X H. A review on weed detection using ground-based machine vision and image processing techniques [J]. *Comput. Electron. Agric.*, 2019,158:226-240.
- [27] ADEL B, ABDOLABBAS J. Evaluation of support vector machine and artificial neural networks in weed detection using shape features [J]. *Comput. Electron. Agric.*, 2018,145:153-160.
- [28] 金小俊,陈勇,侯学贵,等. 基于机器视觉的除草机器人杂草识别[J]. *山东科技大学学报(自然科学版)*, 2012,31(2):104-108.
JIN X J, CHEN Y, HOU X G, *et al.* Weed recognition of the machine vision based weeding robot [J]. *J. Shandong Univ. Sci. Technol. (Nat. Sci.)*, 2012,31(2):104-108.
- [29] OSORIO K, PUERTO A, PEDRAZA C, *et al.* A deep learning approach for weed detection in lettuce crops using multispectral images [J]. *AgriEngineering*, 2020,2(3):471-488.
- [30] 孙哲,张春龙,葛鲁镇,等. 基于 Faster R-CNN 的田间西兰花幼苗图像检测方法[J]. *农业机械学报*, 2019,50(7):216-221.
SUN Z, ZHANG C L, GE L Z, *et al.* Image detection method for broccoli seedlings in field based on faster R-CNN [J]. *Trans. Chin. Soc. Agric. Mach.*, 2019,50(7):216-221.
- [31] 东辉,陈鑫凯,孙浩,等. 基于改进 YOLOv4 和图像处理的蔬菜田杂草检测[J]. *图学学报*, 2022,43(4):559-569.
DONG H, CHEN X K, SUN H, *et al.* Weed detection in vegetable field based on improved YOLOv4 and image processing [J]. *J. Graph.*, 2022,43(4):559-569.
- [32] MORID M A, BORJALI A, DEL F G. A scoping review of transfer learning research on medical image analysis using ImageNet [J/OL]. *Comput. Biol. Med.*, 2021,128:104115 [2024-01-13]. <https://doi.org/10.1016/j.combiomed.2020.104115>.
- [33] JIN X J, CHE J, CHEN Y. Weed identification using deep learning and image processing in vegetable plantation [J]. *IEEE Access.*, 2021,9:10940-10950.
- [34] SIMON K, DORIT M. DELIMIT PyTorch - an extension for deep learning in diffusion imaging [EB/OL]. (2018-08-04) [2024-03-19]. <https://doi.org/10.48550/arXiv.1808.01517>.
- [35] 李梦洁,董蛮. 基于 PyTorch 的机器翻译算法的实现[J]. *计算机技术与发展*, 2018,28(10):160-163,167.
LI M J, DONG L. Implementation of machine translation algorithm based on PyTorch [J]. *Comput. Tech. Dev.*, 2018,28(10):160-163,167.
- [36] 贺丹. 基于 PyTorch 的图像修复技术研究[J]. *电脑知识与技术*, 2022,18(9):75-77.
- [37] 孙艳霞,陈燕飞,金小俊,等. 基于人工智能的青菜幼苗与杂草识别方法[J]. *福建农业学报*, 2021,36(12):1484-1490.
SUN Y X, CHEN Y F, JIN X J, *et al.* AI differentiation of bok choy seedlings from weeds [J]. *Fujian J. Agric. Sci.*, 2021,36(12):1484-1490.
- [38] ZHANG B, GENG Z Y, ZHANG H W, *et al.* Densely connected convolutional networks with attention long short-term memory for estimating PM2.5 values from images [J/OL]. *J. Clean. Prod.*, 2022,333(20):130101 [2024-03-19]. <https://doi.org/10.1016/j.jclepro.2021.130101>.
- [39] CHRISTIAN S, WEI L, YANG Q J, *et al.* Going deeper with convolutions [EB/OL]. (2014-09-17) [2024-03-19]. <https://doi.org/10.48550/arXiv.1409.4842>.
- [40] HE K M, ZHANG X Y, REN S, *et al.* Deep residual learning for image recognition [EB/OL]. (2015-12-10) [2024-03-19]. <https://doi.org/10.48550/arXiv.1512.03385>.